

LAPORAN BIGDATA ANALISIS CASE A – KLASIFIKASI TABULASI

1. Identitas Mahasiswa

Nama : Ridwan

NIM : 20123030

CASE : A – Klasifikasi Tabular (Customer Churn Prediction)

Link github : [readonegate/Learn_Big_Data_Analyst at ETS_BDA_2025](https://github.com/readonegate/Learn_Big_Data_Analyst_at_ETS_BDA_2025)

2. Dataset Dan Deskripsi Masalah

Dataset Dataset yang digunakan dalam proyek ini adalah **Telco Customer Churn** yang diperoleh dari Kaggle. Dataset ini berisi informasi mengenai pelanggan perusahaan telekomunikasi, termasuk demografi, layanan yang digunakan, dan status akun

Tujuan Prediksi Tujuan utama dari analisis ini adalah memprediksi kolom target **Churn** (Yes/No).

Yes: Pelanggan berhenti berlangganan (Churn).

No: Pelanggan tetap berlangganan.

Masalah ini termasuk dalam kategori **Supervised Learning - Classification**. Dengan memprediksi churn, perusahaan dapat mengidentifikasi pelanggan yang berisiko pindah dan melakukan tindakan pencegahan.

Fitur yang Digunakan Berdasarkan analisis korelasi dan relevansi bisnis, fitur utama yang dipilih untuk pemodelan adalah:

- a. tenure (Lama berlangganan)
- b. MonthlyCharges (Biaya bulanan)
- c. TotalCharges (Total biaya)
- d. Contract (Jenis kontrak)
- e. InternetService (Jenis layanan internet)

3. Python Modelling

A. Preprocessing Tahapan pra-pemrosesan data yang dilakukan meliputi :

- a. **Data Cleaning:** Menghapus kolom customerID dan mengubah kolom TotalCharges menjadi tipe numerik (menangani nilai kosong/spasi).

- b. **Handling Missing Values:** Mengisi nilai *missing* pada TotalCharges dengan nilai rata-rata (mean).
- c. **Encoding:** Mengubah variabel kategorikal (seperti Contract, InternetService, Churn) menjadi format numerik menggunakan Label Encoder.
- d. **Splitting Data:** Membagi data menjadi 70% Data Latih (Train) dan 30% Data Uji (Test) dengan *stratify* agar proporsi target seimbang.

B. Hasil Evaluasi Model (Python)

Dua model algoritma digunakan sebagai perbandingan: **Logistic Regression** (Baseline) dan **Decision Tree**.

```
=====
HASIL EVALUASI: Logistic Regression
=====
Akurasi: 78.28%

Confusion Matrix:
[[1381  171]
 [ 288  273]]

Classification Report:
              precision    recall  f1-score   support

     0       0.83         0.89         0.86         1552
     1       0.61         0.49         0.54          561

 accuracy          0.78         0.78         0.78         2113
 macro avg          0.72         0.69         0.70         2113
weighted avg          0.77         0.78         0.77         2113

=====
HASIL EVALUASI: Decision Tree
=====
Akurasi: 77.90%

Confusion Matrix:
[[1453   99]
 [ 368  193]]

Classification Report:
              precision    recall  f1-score   support

     0       0.80         0.94         0.86         1552
     1       0.66         0.34         0.45          561


 accuracy          0.73         0.64         0.66         2113
 macro avg          0.73         0.64         0.66         2113
weighted avg          0.76         0.78         0.75         2113
```

Model 1: Logistic Regression

- a. **Akurasi: 78.28%**
- b. **Analisis:** Model ini memiliki performa yang cukup stabil dengan nilai F1-score rata-rata tertimbang (weighted avg) sebesar 0.77. Namun, *recall* untuk kelas Churn (1) masih rendah (0.49), artinya model baru bisa mendeteksi separuh dari total pelanggan yang sebenarnya churn.

Model 2: Decision Tree


- a. **Akurasi: 77.90%**
- b. **Analisis:** Akurasi sedikit lebih rendah dibanding Logistic Regression. *Recall* untuk kelas Churn turun menjadi 0.34, yang berarti model ini lebih konservatif dan banyak melewatkan pelanggan yang sebenarnya berpotensi churn (False Negative tinggi)



4. KNIME Workflow

Workflow dibangun untuk mereplikasi proses yang dilakukan di Python, mulai dari pembacaan data hingga evaluasi.


A. Screenshot Workflow Workflow terdiri dari node: *CSV Reader* -> *Preprocessing* (String to Number, Missing Value, Column Filter) -> *Partitioning* -> *Learner* (Logistic & Decision Tree) -> *Predictor* -> *Scorer*.



B. Hasil Evaluasi Model (KNIME)


Berikut adalah hasil *Confusion Matrix* dan Akurasi dari KNIME:

1. Logistic Regression Results



- Akurasi: 77.615%**
- Error Rate: 22.385%
- Model berhasil memprediksi dengan benar 1452 pelanggan setia (No) dan 188 pelanggan churn (Yes).

2. Decision Tree Results



- Akurasi: 72.788%**
- Error Rate: 27.212%

- c. Meskipun akurasi total lebih rendah, model Decision Tree di KNIME berhasil mendeteksi pelanggan churn lebih banyak (**276 orang**) dibandingkan Logistic Regression (188 orang). Namun, hal ini diikuti dengan peningkatan "False Alarm" (False Positive) sebanyak 290 orang

5. Kesimpulan

Berdasarkan percobaan menggunakan Python dan KNIME, dapat ditarik kesimpulan sebagai berikut:

1. **Model Terbaik: Logistic Regression.**
 - a. Pada Python, Logistic Regression mencapai akurasi tertinggi (**78.28%**).
 - b. Pada KNIME, Logistic Regression juga konsisten unggul dengan akurasi (**77.61%**) dibandingkan Decision Tree (**72.78%**).
2. **Interpretasi:** Logistic Regression terbukti menjadi model yang lebih *robust* (kokoh) dan stabil untuk dataset *Telco Customer Churn* ini dibandingkan Decision Tree standar. Decision Tree cenderung mengalami *overfitting* atau ketidakstabilan tergantung pada parameter kedalaman (depth) dan cara pembagian data (splitting).
3. **Rekomendasi:** Untuk implementasi nyata, Logistic Regression direkomendasikan karena akurasinya yang lebih tinggi. Namun, jika perusahaan ingin lebih agresif menangkap pelanggan yang berpotensi kabur (walaupun dengan resiko salah tebak), Decision Tree bisa dipertimbangkan karena memiliki sensitivitas deteksi churn yang lebih tinggi pada simulasi KNIME